影像處理 HW2

109550087 單宇晟

原理介紹

- Deep learning

深度學習是機器學習的一個子領域，藉由訓練具有多層的neuron network，以執行圖像識別、語音識別、自然語言處理等任務。深度學習模型由多層相互連接的節點組成，每個節點會對其input套用一個數學函式，並將結果傳遞給下一層。每一層都會從input的數據中提取越來越複雜的特徵，使整個model能夠做出更準確的預測或執行更複雜的任務。深度學習模型使用大量labeled過的數據進行train，並在train的過程中不斷改變節點之間的weight，以盡量減少預測結果的誤差。深度學習的優勢是它能夠從原始數據中自動學習特徵，而不是像傳統機器學習那樣依賴手動去label。

- Multilayer perceptron

多層感知器（MLP）也是一種neuron network，由多層相互連接的neuron組成，每一層的每個neuron都會收到前一層中所有neuron的輸入。MLP的第一層是輸入層，會接收到最原始的數據；中間層又被叫做隱藏層，最後一層則是輸出層，會產生整個網絡最後的output。和deep learning的概念一樣，MLP中的每個neuron會對其input套用一個函式，產生出的的output就會被當作input傳遞給下一層的所有neuron，同時在train的過程中調整neuron之間的weight，達到理想的預測結果。

- Implicit Neural Representation

隱式神經表示（INR）是深度學習的一種技術，能夠用緊湊和高效的方式表示複雜的幾何體或物體。與傳統的幾何表示不同，傳統的幾何表示需要明確的參數化或表面特徵，INR模型則是能透過neuron network去define。在建立INR model的時候，首先會將空間中的一個點作為input，然後output一個代表物體屬性的value，像是該點與表面的距離或物體的顏色。通過對空間中的許多點進行sampling，並在每個點上對model去進行evaluate，就可以重建物體的完整表徵。

- View synthesis

View synthesis是computer graphics的一種技術，會從一組現有的view中生成場景或物體的新的viewpoint。View synthesis的目標是創建一個可以在場景或物體周圍移動的虛擬camera，並生成新的視角，而不需要再做額外的input。View synthesis是基於幾何學、或是影像的組合方法來實現的。幾何方法包括從現有

的view中計算場景或物體的三維結構，然後透過將三維結構投射到虛擬camera上去，然後render新的viewpoint；基於圖像的方法則是通過使用deep learning去學習input的view和output的view之間的映射，從現有view中合成新的viewpoint。

- NeRF (Neural Radiance Fields)

NeRF 是一種比較新的深度學習方法，可以從二維圖像合成三維場景。NeRF 使用一個叫做 radiance field 的連續函數來表示場景，它會透過 train 一個深度神經網絡來預測三維空間中每個點的顏色和不透明度。在 train 的過程中，會 input 一組從不同 viewpoint 拍攝的場景的二維圖像，之後就會進行優化，minimize 預測的 radiance 和輸入圖像的 radiance 之間的差異。經過 training 之後，radiance field 就能夠透過整合從相機位置到場景的三維空間射線的 radiance，來 render 來自其他視角的新視圖。

實作方法

- Colmap

In the beginning, I follow the instructions on github to install COLMAP-3.8-windows-cuda, where it has a Colmap.bat file. Next, I take a series of photo, each of them should have an overlap between each other. Then, in Colmap, I first extract the feature. After this, we can start to match the features across the images. Next I sparse 3D reconstruction from the matched features, which will create a sparse 3D point cloud and camera poses from a set of 2D images. The point cloud represents the structure of the scene in 3D. Finally, we can get the following files: cameras.bin, images.bin, points3D.bin and project.ini.

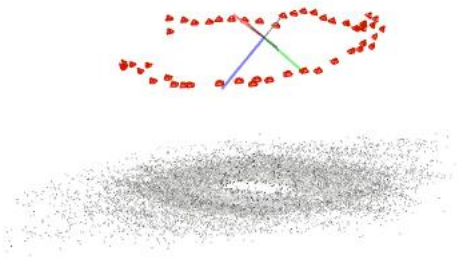

- 深度學習網路

train.py

The whole program use only one class—NeRFSystem. The constructor initializes the model's hyperparameters, loss function, and two embedding layers, one for XYZ coordinates and the other for viewing directions. It also initializes NeRF model. Next is the decode_batch(), it extracts rays and ground truth colors from a batch of data. And forward() performs batched inference on rays using NeRF model, where many hyperparameters are set. Then returns the predicted colors, depths, and other intermediate results. Fourth, prepare_data() loads the training and validation datasets. Fifth, configure_optimizers() just sets up the optimizer and learning rate. Next are train_dataloader() and val_dataloader(), they are very similar. Both of them return DataLoader objects for the training and validation datasets respectively. Then, comes training_step() and validation_step(), they define the forward pass for the model during training and validation respectively. The training_step() calculates the loss, PSNR, and learning rate, and returns a dictionary. The validation_step() also calculates the loss and PSNR and returns a dictionary. Last but not least, validation_epoch_end() calculates the mean validation loss and PSNR over all validation batches.

Nerf.py

This code has 2 class: Embedding and NeRF. They both contains only constructors and forward(). For Embedding, it embed input data x into a new representation by concatenating x with its sin() and cos() values. For NeRF, it implements a NeRF model, which takes input as an embedded vector of position and direction, then encodes it into a new representation. In the end, the model can predict the color and density at some points (other than input points). This NeRF model consists of multiple layers neural networks, which are used to encode the position and direction. And the output layers are for predicting color and density.

- 使用方法

基本上我都是照著 github 上的指令去做 training，command 如下：

```
(base) 311554019@c006:~/nerf_pl$ python train.py \
>    --dataset_name llff \
>    --root_dir /home/311554019/workspace \
>    --N_importance 64 --img_wh 300 169 \
>    --num_epochs 20 --batch_size 2048 \
>    --optimizer adam --lr 5e-4 \
>    --lr_scheduler steplr --decay_step 10 20 --decay_gamma 0.5 \
>    --exp_name exp \
>    --spheric
```

我首先更改了 root_dir，設成自己 file 的 path、num_epochs 設成 20、img_wh 則要跟自己拍攝的照片的 height、width 一樣、batch_size 我設成 2048、最後，

因為是做 360 inward-facing，所以加上—spheric。

```
(base) 311554019@c006:~/nerf_pl$ python eval.py \
>    --root_dir /home/workspace \
>    --dataset_name llff --scene_name ep20 \
>    --img_wh 300 169 --N_importance 64 --ckpt_path /home/311554019/nerf_pl/ckpts/exp/epoch=9.ckpt \
>    --spheric_poses
```

Test 的部分，一樣把 root_dir 設好，dataset_name 要改成 llff，img_wh 也跟上面一樣，改成自己照片的 size、並在 ckpt_path 中設好這次要 evaluate 的 ckpt 檔、最後一樣加上—spheric 就可以了。

深度學習模型訓練及評估結果

- Training

Epoch	10	15	20
PSNR (val)	22.3551	22.4218	22.3415

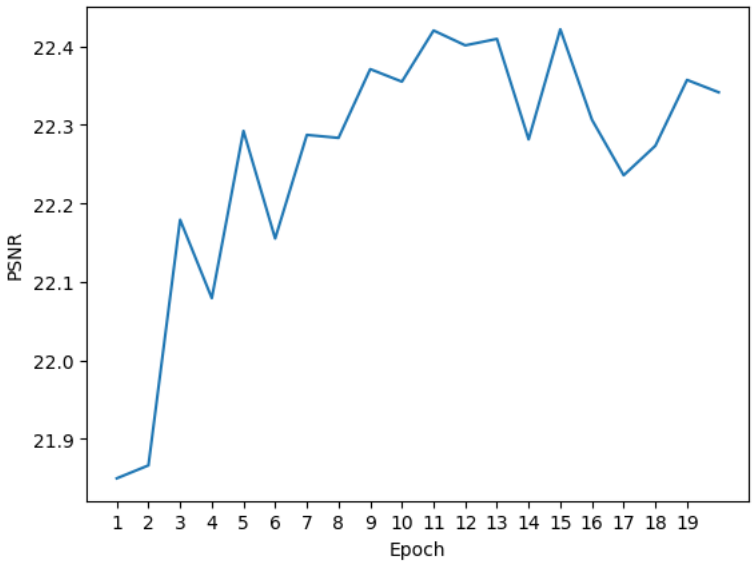

在我 training 的過程中，可以發現，在前 12 個 epoch 左右的 psnr 是呈現一個上升的趨勢，然而過了 epoch 12 之後，psnr 就開始震盪，並且有時還會降低，以下是我認為可能的原因：

(1) overfitting，過了 epoch 12 之後，model 已經適當的 train 到一個段落了，之後的 epoch 就造成 overfitting

(2) learning rate，有可能 learning rate 設太大，或是一開始不變，在 psnr 開始震盪的時候，learning rate 要變小一點，model 才不會圍繞 optimal result 震盪，無法收斂

(3) dataset，照片本身的解析度、大小(height, width)都會影響 train 的結果，拍攝的一連串照片之間的角度、遠近是否差距太大也會影響最終的結果；理想情況下，每張照片之間的角度差距應該要一樣、且和物體的距離也應該相同。

(4) 其他 hyperparameter，NeRF 這個 model 也有用到其他 hyperparameter，有可能其他 hyperparameter 也要調整

- Testing

就肉眼觀察來說，我認為三張 gif 的表現其實差別不大，雖然 epoch 12 之後的 psnr 比較不穩定，但剛好我拿出來比較的 epoch 15、20 都沒有太大的變動，三者 psnr 的差距都在 0.1 之內，所以我覺得這結果是合理的。不過還是有一些比較明顯的差距：epoch 10 的 gif 在環繞的時候，相比其他兩張會出現模糊的時候比較多，雖然 epoch 15、20 的 gif 有時候也會，但相比較少；另外，三張 gif 的上半部都出現模糊的情況(有點像烏雲，如圖)，我覺得這跟我拍攝的場景有關，有可能是因為巧拼的花紋導致的結果，也有可能是因為我的拍攝主體(滑鼠)和場景的顏色差距不太(白、灰)，造成這種結果。

分析討論

- INR

Pros

INR models are generally more compact and computationally efficient than NeRF models, since they can be learned with simpler neural networks.

Cons

However, INR models are usually more difficult to train than NeRF models, because their loss functions need to be carefully designed, and carefully regularized to avoid overfitting. Moreover, the result of INR models are usually worse than NeRF in showing details and lighting effects. In fact, INR are only trained to represent a single property of the scene.

- NeRF

Pros

NeRF models can represent very high-quality renderings of scenes with complex lighting effects and materials. NeRF models can be trained to represent multiple properties of the scene, just like this homework, it can show color, lighting, normal vector and etc.

Cons

On the other hand, NeRF models are computationally expensive to train and render, as they require the integration of a high-dimensional function along each ray passing through the 3D space. In fact, it took me almost 20 hours to train a model with 20 epochs.

這次 homework 主要是讓我們了解 NeRF 的運作，我遇到的第一個難題，就是架設環境，由於原作者使用的版本太舊了，所以光是架設環境就耗費我不少時間，之後在 train 的時候又遇到 CUDA error: out of memory 的問題，幸好我有來得及去借設備。另外，我這次其實不只拍照一次，在第一次準備 dataset 的時候，我沒有注意到拍攝的距離問題，相機忽遠忽近，結果導致 model 無法進行 training，之後我才重拍一次，盡量用同等距離、高度去拍攝；另外照片的解析度也很重要，如果解析度太高，會讓 colmap 有 feature exhaust 的問題，之後我就把照片大小 resize 到 600x338，但這樣的設置似乎還是不夠小，做 training 的每個 epoch 的時間太久(一個 epoch 大概 100 分鐘)，於是我就再重新 resize 成 300x169，時間就快上許多(一個 epoch 大概 40 分鐘)；不過或許是解析度太低的問題，我 train 出來的結果都有些模糊，如果時間允許的話，我會想試試看用高解析度的 dataset 去做 training，並提高 dataset 的 size(我目前是 53 張)，這樣的結果應該會有所差異。